Цифровое развитие регионов России: пространственная кластеризация, 2021

Практики 11–12 · Анализ данных и машинное обучение · магистратура 09.04.01

Команда 4: Зуев Андрей Александрович, Васильев Александр Викторович, Мамшева Юлия Сергеевна

НГИЭУ, 2026

Задача: типы регионов по цифровому развитию и их география

17080100

Домохозяйства с ПК

% домохозяйств

17080200

Домохозяйства с доступом в интернет

% домохозяйств, с любого устройства

17080300

Домохозяйства с широкополосным доступом

% домохозяйств

17090200

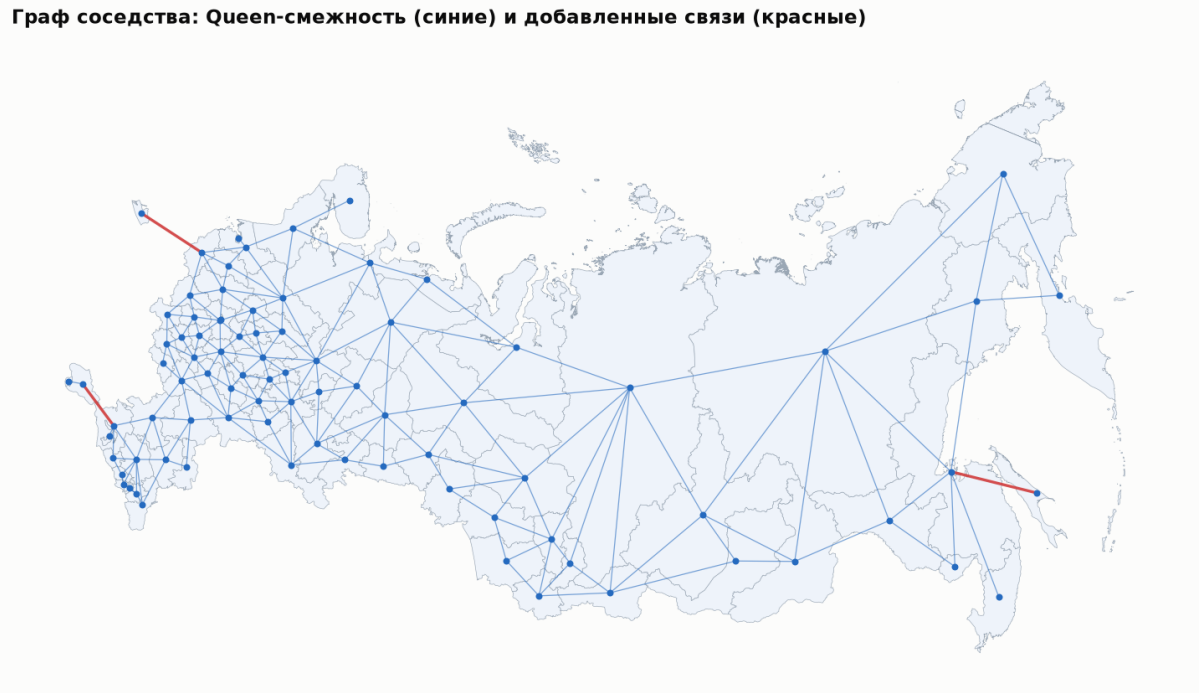
Ежедневные пользователи интернета

% населения 15–74 лет

- Источник: Росстат, «Регионы России. Социально-экономические показатели», машиночитаемая версия tochno-st/regions_collection, 2021 год
- Выборочное обследование населения по вопросам использования ИКТ: есть ошибка выборки
- Единица анализа — 85 субъектов РФ (в границах 2021 года), без строк «Россия» и федеральных округов
- Требование задания: не менее трёх методов кластеризации, в том числе учитывающих пространственные отношения

Геопространственная база: 85 единиц, ключ — ОКАТО

- Границы: OpenStreetMap (timurkanaz/Russia_geojson_OSM), 85 полигонов, EPSG:4326 → равновеликая проекция Альберса для России
- Архангельская и Тюменская области взяты «без АО»: иначе НАО, ХМАО и ЯНАО учитывались бы дважды
- Найдена ошибка источника: ОКТМО «Архангельской области без АО» = ОКТМО НАО → соединение по уникальному ОКАТО, 85 из 85
- Пропусков нет; геометрия валидна, наложений нет; упрощение 2 км не меняет соседства
- Ограничение: полигон Москвы в границах до 2012 г. — на соседство и данные не влияет



Уровень высокий, сильнее всего различается наличие ПК

72–98,5 %

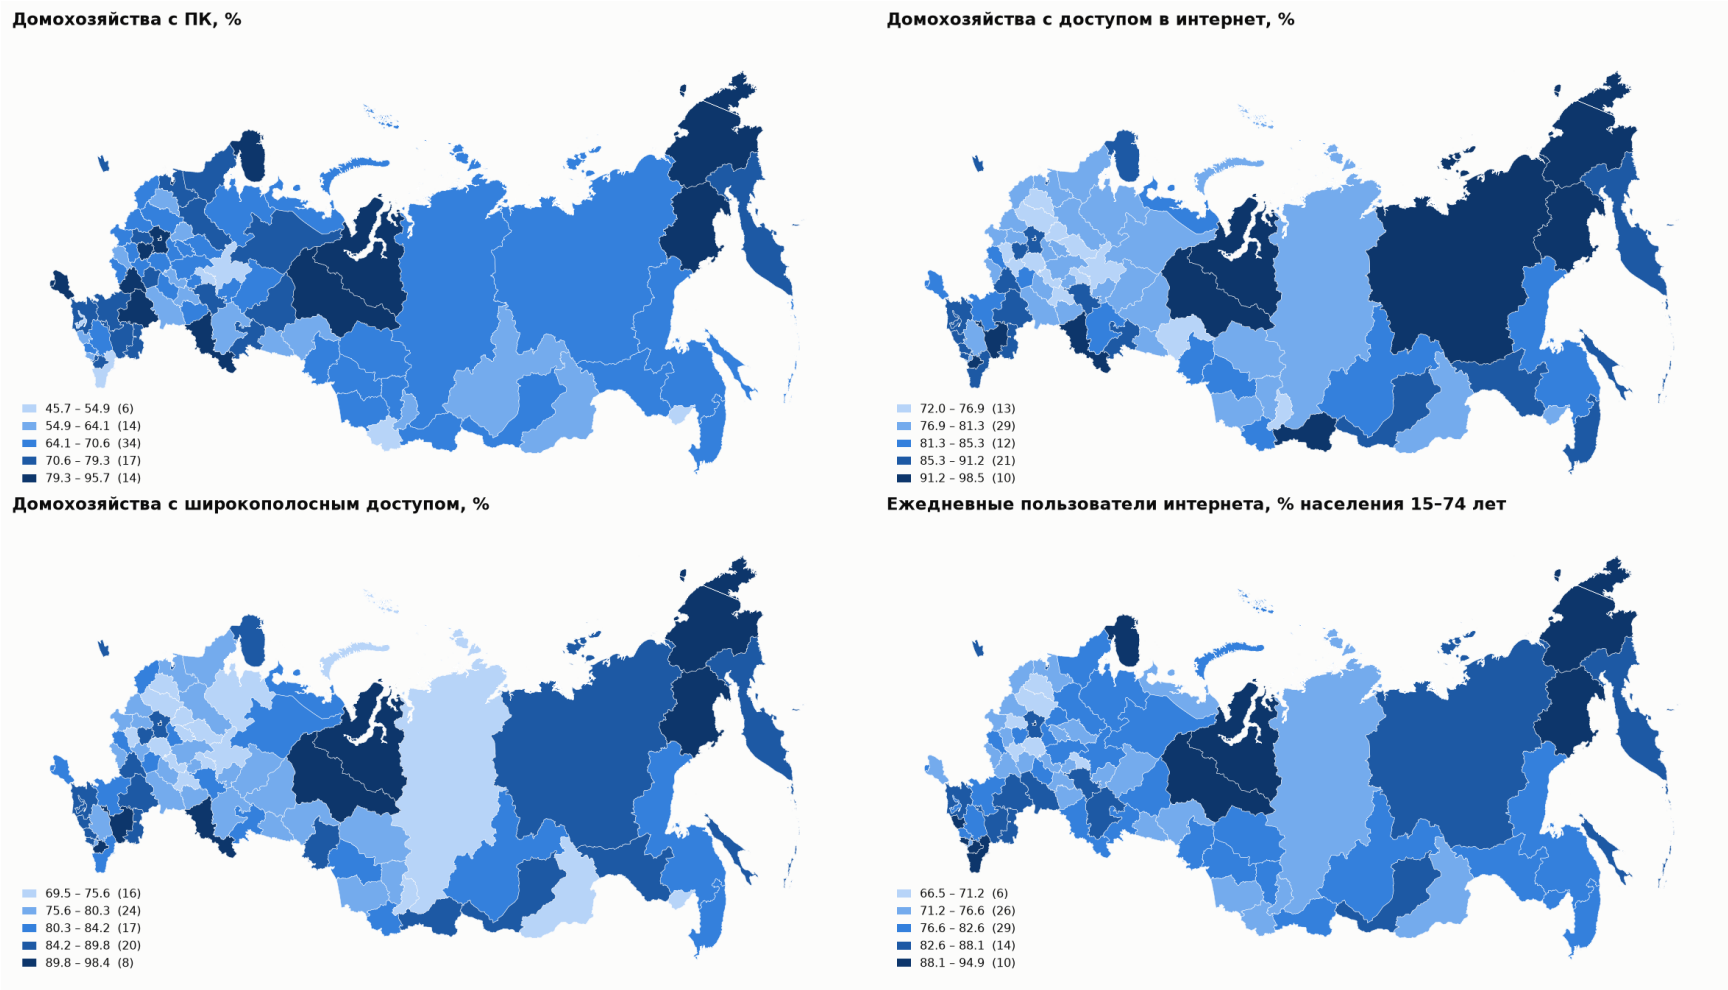
домохозяйств с доступом в интернет: от Марий Эл до ЯНАО

45,7–95,7 %

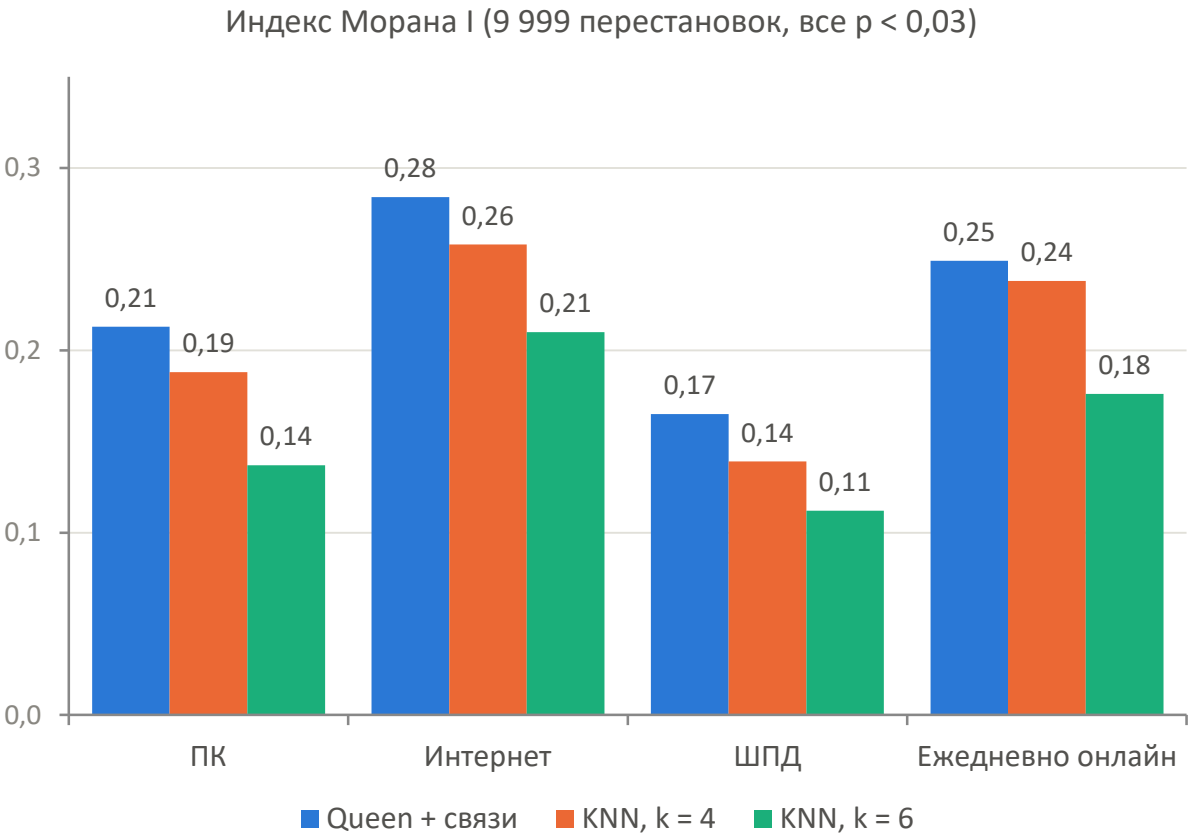
домохозяйств с ПК: наибольший разброс, CV 13 %

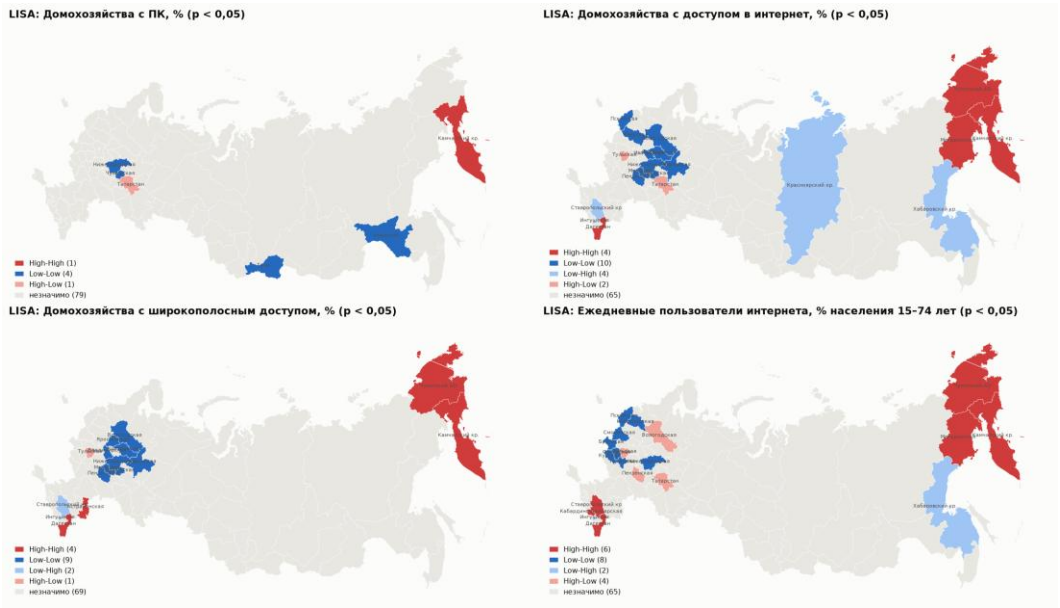
$|\gamma_1| < 0{,}5$

асимметрия мала — логарифм не нужен, достаточно стандартизации



Автокорреляция значимая, но умеренная





- High-High: северо-восток Дальнего Востока, восток Северного Кавказа
- Low-Low: массив Центра и Поволжья
- После поправки FDR значимы 0–4 региона на показатель

Две оси: общий уровень и «ПК против смартфона»

r = 0,96

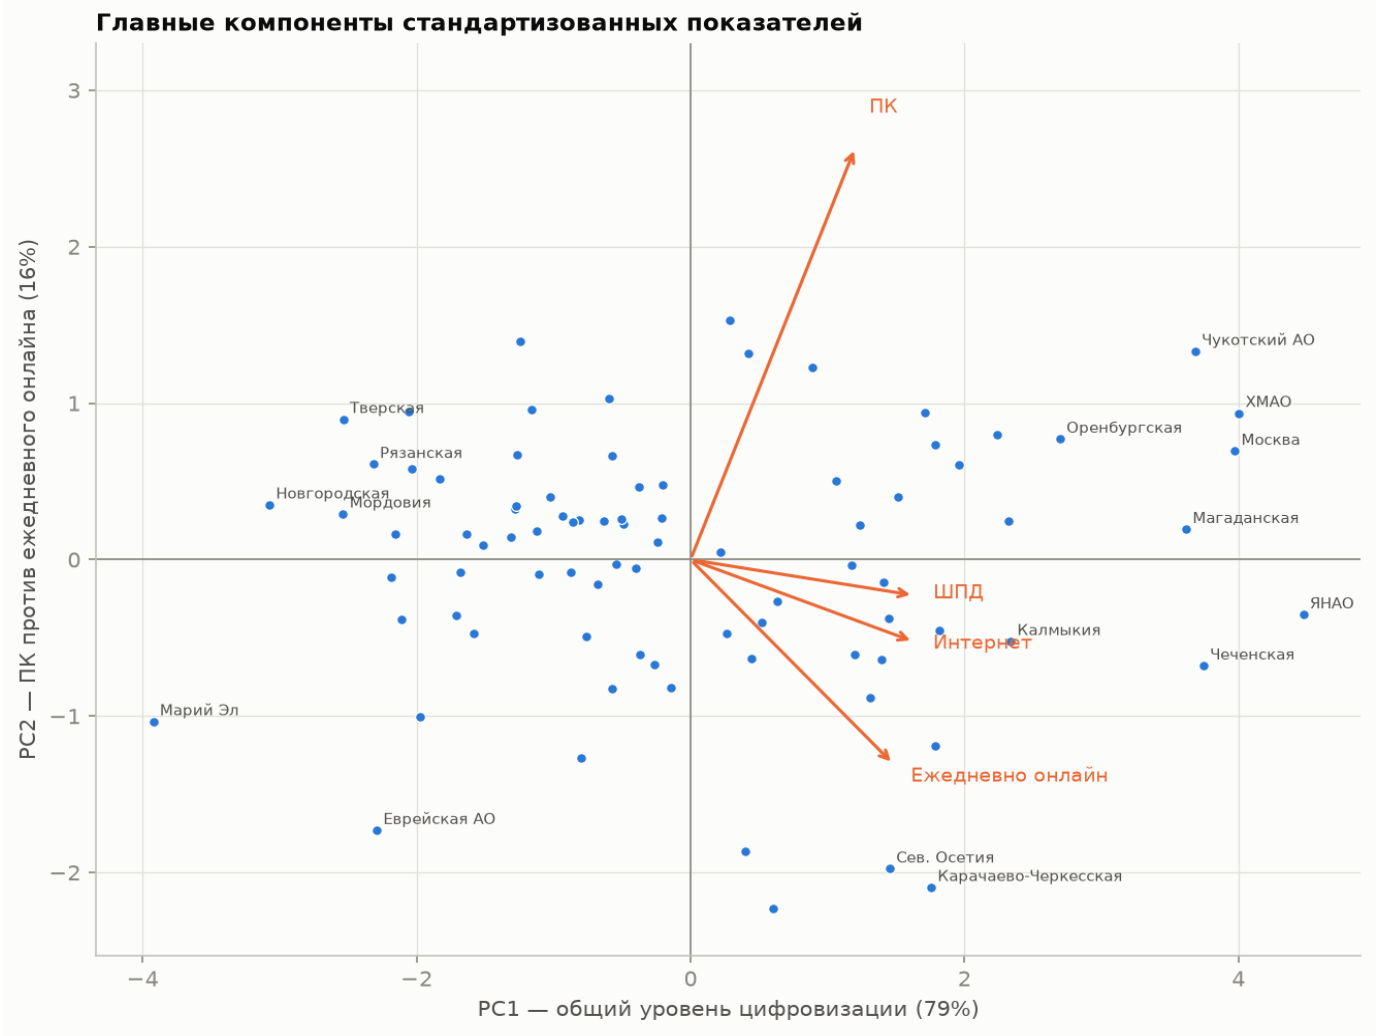
интернет и ШПД почти дублируют друг друга

PC1 = 78,5 %

общий уровень цифровизации, все нагрузки 0,40–0,55

PC2 = 15,6 %

ПК (+0,88) против ежедневного онлайна (−0,44): «мобильная» модель



Пять методов: от типологии к жёсткому районированию

1

k-средних

без учёта пространства

k = 5, 200 стартов k-means++

2

ClustGeo

мягкий учёт

Уорд на $(1-\alpha)D_0^2 + \alpha D_1^2$, D_1 — шаги по графу; $\alpha = 0{,}25$

3

Уорд со смежностью

жёсткая связность

объединяются только соседние кластеры

4

SKATER

жёсткая связность

разрезание минимального остовного дерева; ≥ 3 региона

5

Max-p

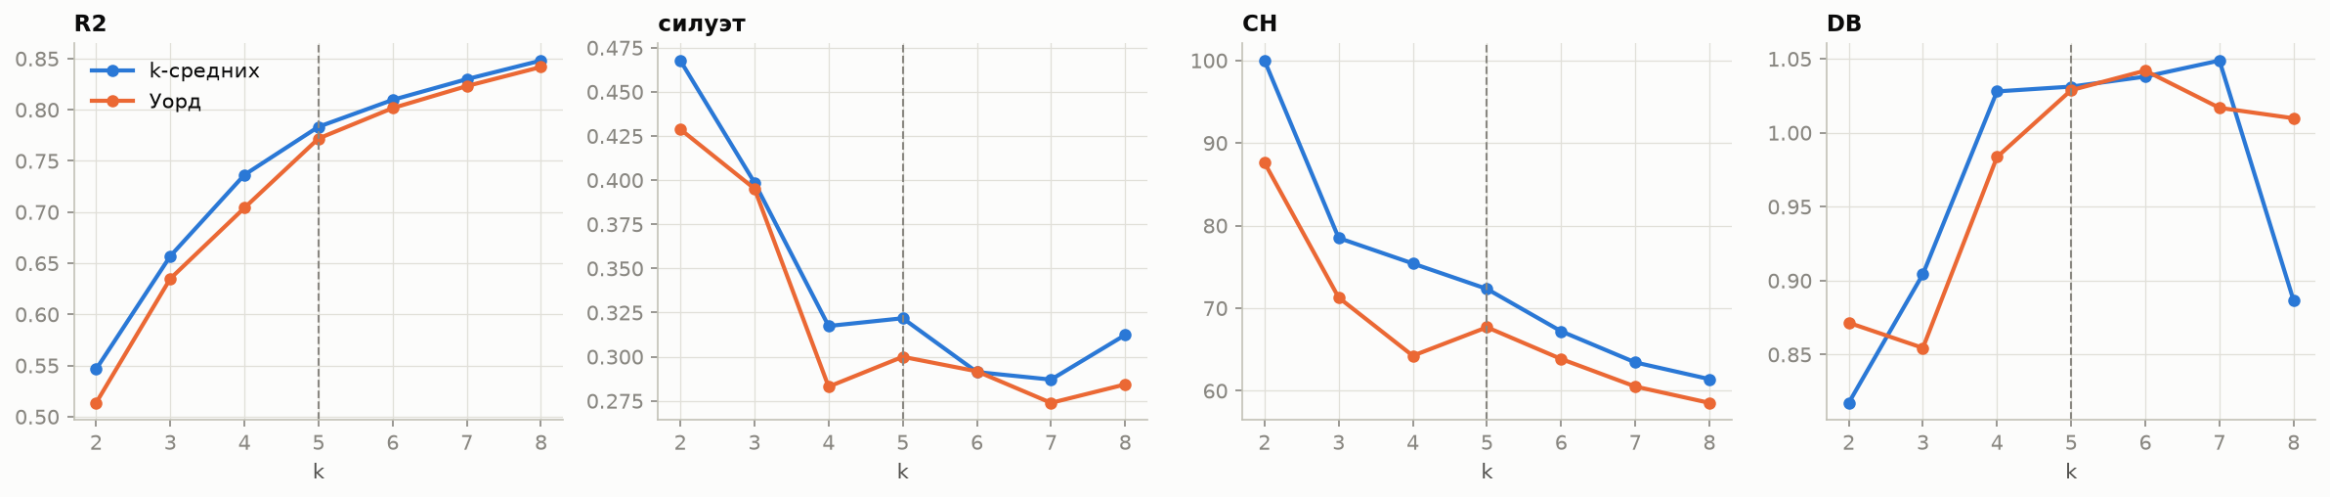
жёсткая связность, p из данных

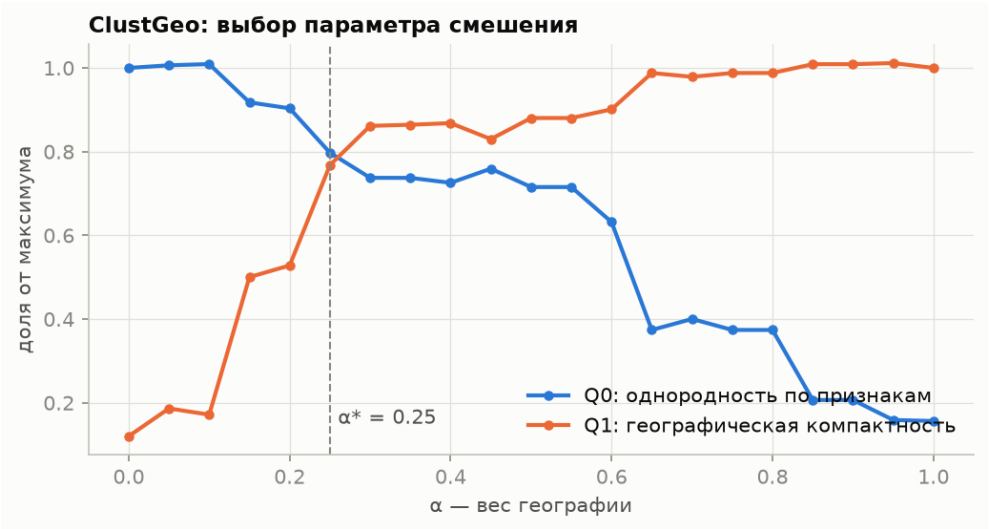
население кластера ≥ 15 млн → p = 8

однородность по признакам → территориальная связность

Пространство признаков — 4 z-оценки; граф соседства — Queen с подключёнными изолированными регионами

Выбор параметров: k = 5 и α = 0,25





- Силуэт максимален при k = 2 — это тривиальное «выше/ниже среднего»; среди k ≥ 3 максимум при k = 5 (0,322)
- «Локоть» R^2: +4,7 п. п. от 4 к 5 кластерам, дальше 2–3 п. п.; наименьший кластер — 7 регионов
- α ClustGeo — по критерию авторов метода: нормированные доли однородности по признакам и по географии пересекаются при α = 0,25 (0,80 и 0,77)

«Цена» связности — больше половины однородности



Итог: k-средних — лучший средний ранг (2,25) по качеству, устойчивости и интерпретируемости. Жёсткая связность снижает R^2 с 0,78 до 0,32–0,39 и даёт вырожденные или неустойчивые разбиения. ClustGeo — компромисс для карт: вдвое больше связей внутри кластеров при $R^2 = 0,62$. Разбиение k-средних почти не меняется в пространстве двух главных компонент (ARI = 0,98).

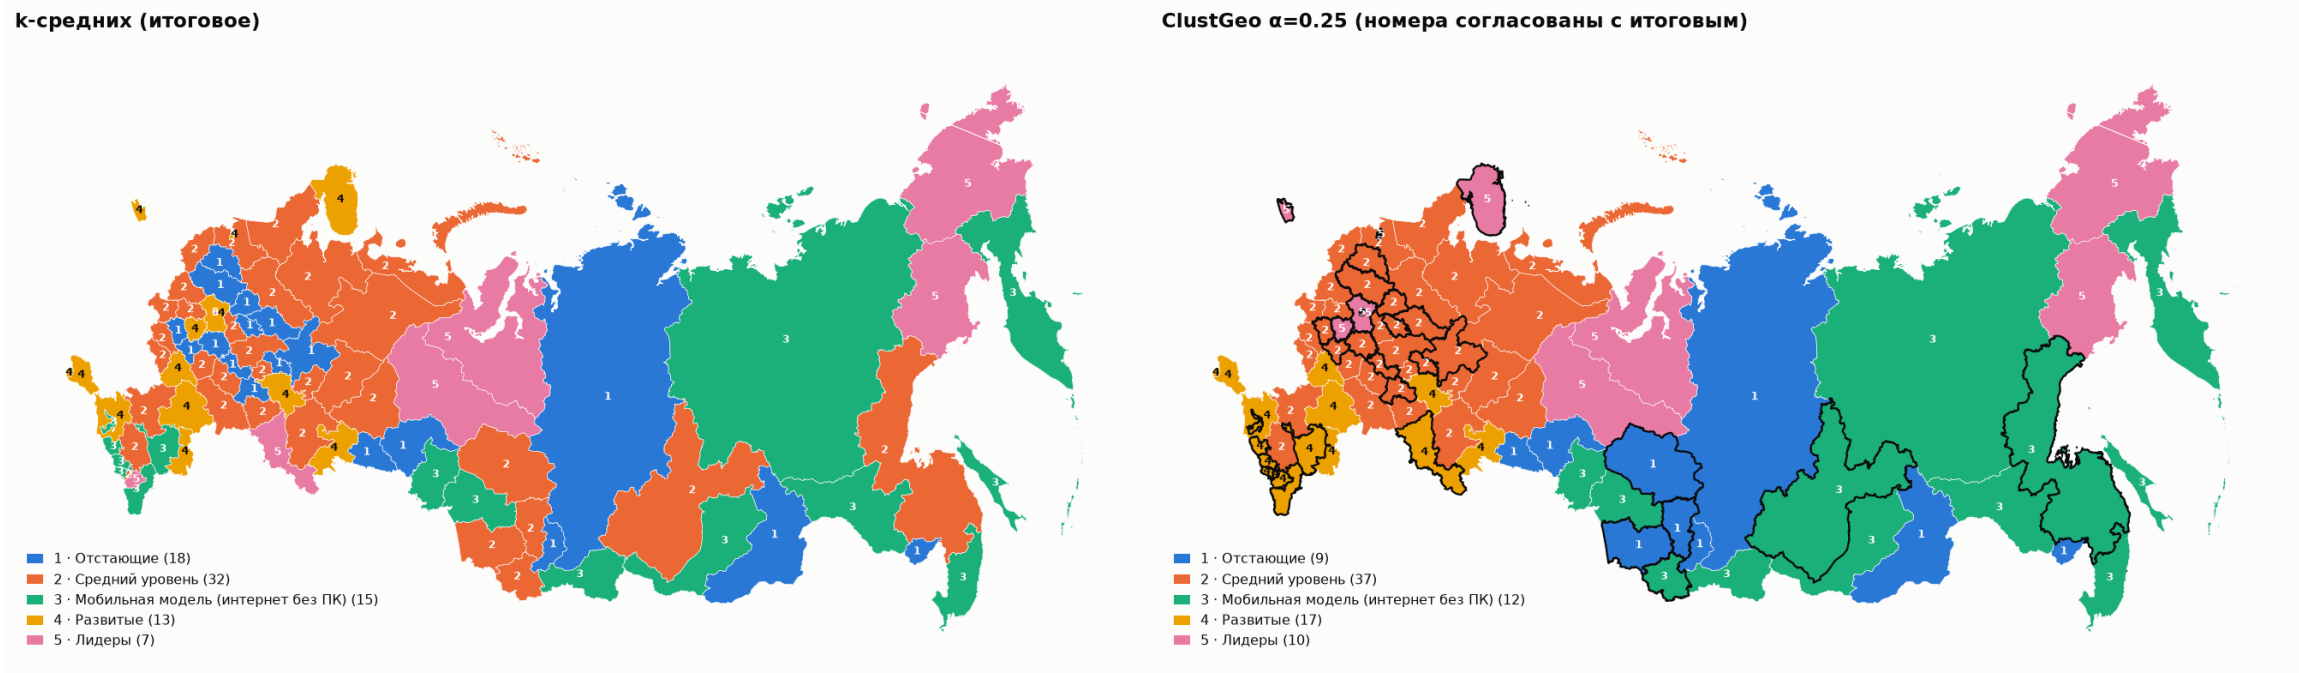
Пять типов регионов по цифровому развитию населения



k-средних, k = 5 · R^2 = 0,78 · силуэт 0,32 · отрицательный силуэт только у Новосибирской и Оренбургской областей

- **1 · Отстающие (18)** все показатели на 0,9–1,3σ ниже среднего: Центр, Поволжье, часть Сибири
- **2 · Средний уровень (32)** чуть ниже среднего, самый массовый тип
- **3 · Мобильная модель (15)** интернет +0,9σ при ПК −0,4σ: Северный Кавказ, Сибирь, Дальний Восток
- **4 · Развитые (13)** много ПК (+1,1σ): Подмосковье, Петербург, Краснодар, Татарстан, Крым
- **5 · Лидеры (7)** +1,7–2,0σ: Москва, ХМАО, ЯНАО, Чукотка, Магадан, Оренбург, Чечня

Неравенство мозаичное, а не макрорегиональное



0 из 5

типов образуют значимое территориальное сгущение (join count, p < 0,05); ближе всего «Отстающие», p = 0,06

53 из 85

регионов сохраняют тип при учёте географии (ClustGeo); меняют тип «выбивающиеся» из окружения

4 ФО

«мобильная модель» только на Северном Кавказе, юге, в Сибири и на Дальнем Востоке

Выводы и ограничения

Выводы

- Две оси цифровизации: общий уровень (78,5 %) и «ПК против смартфона» (15,6 %)
- Автокорреляция значимая, но умеренная: I = 0,17–0,28 при любой схеме соседства
- Пять устойчивых типов (k-средних, ARI 0,86); жёсткое районирование теряет > 50 % однородности
- Неравенство мозаичное → адресная региональная политика вместо программ по ФО

Ограничения

- Выборочное обследование, самооценки респондентов; ошибка выборки не публикуется
- Один год (2021): ни динамики, ни причинности
- MAUP: субъекты несопоставимы по площади, внутрирегиональные различия скрыты
- Добавленные связи Калининград, Сахалин, Крым — допущение для связности графа