Цифровое развитие регионов России: пространственная кластеризация, 2021

Практики 11–12 · Анализ данных и машинное обучение · магистратура 09.04.01

Команда 4: Зуев Андрей Александрович, Васильев Александр Викторович, Мамшева Юлия Сергеевна · НГИЭУ, 2026

85

субъектов РФ, 4 показателя Росстата за 2021 год

7

методов кластеризации: от типологии до жесткого районирования

5

типов регионов; итог — k-средних, R^2 = 0,78, устойчивость ARI = 0,84

0,17–0,28

Moran's I: соседство значимо, но умеренно → неравенство мозаичное

Задача: типы регионов по цифровому развитию и география

Четыре показателя одного выборочного обследования Росстата; единица анализа — субъект РФ; требуется не менее трех методов, в том числе с учетом соседства

Код	Показатель (обозначение)	База	Мин – макс, 2021
17080100	Домохозяйства с ПК (pc)	% домохозяйств	45,7 – 95,7
17080200	Доступ в интернет с любого устройства (internet)	% домохозяйств	72,0 – 98,5
17080300	Широкополосный доступ, ШПД (broadband)	% домохозяйств	69,5 – 98,4
17090200	Пользуются интернетом (почти) каждый день (daily_users)	% населения 15–74	66,5 – 94,9

- **Источник:** Росстат, «Регионы России. Социально-экономические показатели», машиночитаемая версия tochno-st/regions_collection, раздел 17
- **Обследование выборочное:** есть ошибка выборки (≈1–2 п. п.), поэтому отдельно проверяем устойчивость к ней
- **Население 2021 (01010000)** — только для ограничения метода Max-p

Требование задания	Где выполнено
Геопространственная база, проверки соответствия	шаг 1 · ноутбук 01 · слайд 3
Визуализация и пространственная диагностика	шаг 2 · ноутбук 02 · слайды 4–6
≥ 3 методов, в том числе с учетом соседства	7 методов · ноутбук 03 · слайды 7–8
Сравнение по системе показателей, выбор	шаг 4 · ноутбуки 03–04 · слайды 9–11
Итоговые карты, профили, выводы	шаг 5 · ноутбук 04 · слайды 12–16

Содержательно

Выделить группы регионов со сходным уровнем и структурой цифрового развития, затем проверить, образуют ли группы сплошные территории.

Формально

$$\min \sum_c \sum_{i \in C_c} \| z_i - \bar{z}_c \|^2$$

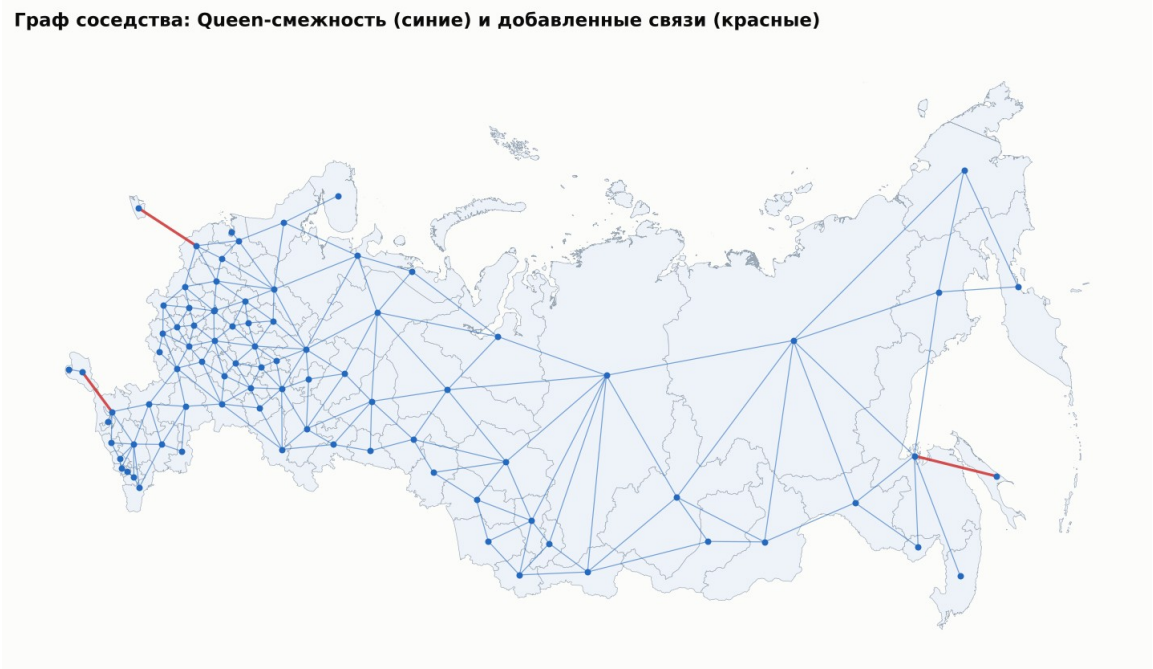
z — стандартизованные признаки, W — граф соседства

- **без ограничений** — типология (k-средних, Уорд)
- **мягкий учет** — к различию признаков добавлено географическое (ClustGeo)
- **жесткий** — каждый кластер связен в W (Уорд со смежностью, SKATER, AZP, Max-p)

Геобаза: 85 непересекающихся территорий, ключ — ОКАТО

Ноутбук 01: отбор строк, сопоставление с границами OSM, проверки, матрица соседства

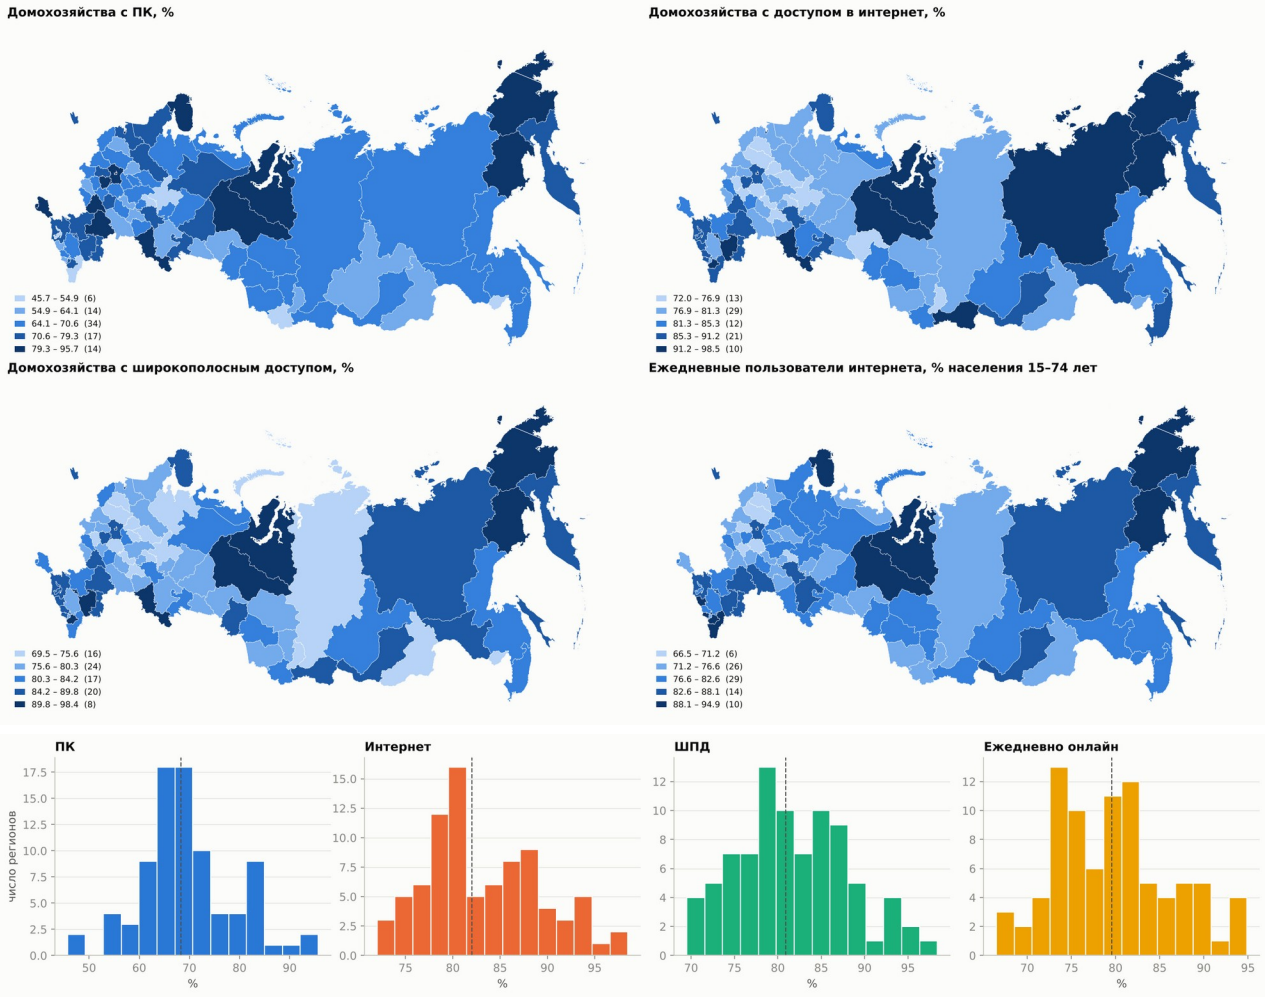
1. **Отбор строк.** 87 строк уровня «регион» → 85: Архангельская и Тюменская области взяты «без АО», иначе НАО, ХМАО и ЯНАО учитывались бы дважды
2. **Ключ ОКАТО.** в источнике ОКТМО «Архангельской обл. без АО» = ОКТМО НАО (11800000); ОКАТО уникальны
3. **Границы.** OpenStreetMap, 85 полигонов; названия сверены со справочником регионов, соответствие 85 из 85 (one-to-one)
4. **Проверки.** пропусков нет; геометрия валидна; наложений 0 км²; население 145,56 млн = итог по РФ
5. **Проекция.** Альберса для России (lon_0 = 100°): верные площади, Чукотка через 180° одним массивом
6. **Соседство.** Queen + 3 связи для островных частей: Калининград–Псков (362 км), Сахалин–Хабаровский кр. (8 км), Крым–Краснодарский кр. (≈1 км)



85 / 85	0	4,5	1
сопоставлено	пропусков	соседа в среднем (1–9)	компонента графа

Уровень высокий, сильнее всего различается наличие ПК

Ноутбук 02: описательная статистика, тематические карты (интервалы Фишера–Дженкса), выбор преобразования



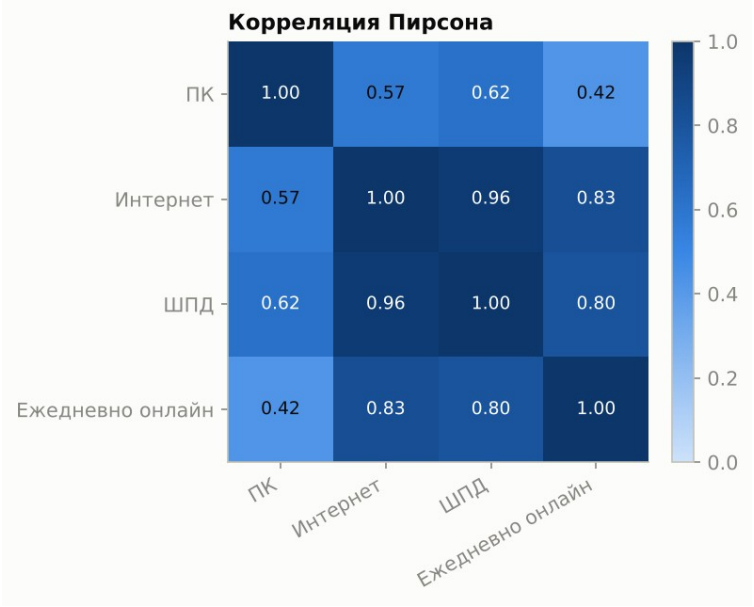
Показатель	Среднее	σ	CV, %	Минимум	Максимум
ПК	69,8	9,4	13,4	45,7 Марий Эл	95,7 Чукотка
Интернет	83,3	6,2	7,4	72,0 Марий Эл	98,5 ЯНАО
ШПД	81,8	6,5	7,9	69,5 Новгородская	98,4 ЯНАО
Ежедневно	79,8	6,7	8,3	66,5 Тверская	94,9 ЯНАО

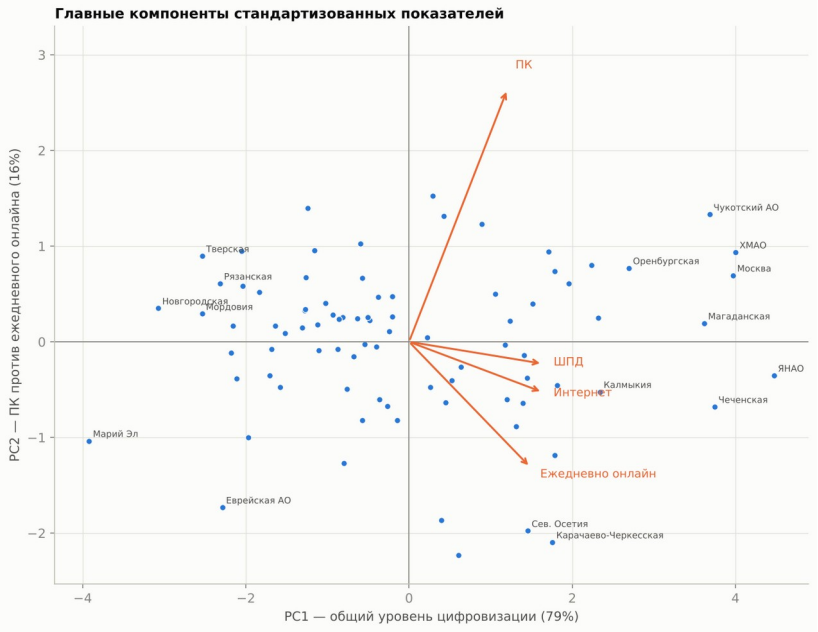
Что из этого следует

- **Асимметрия 0,31–0,46** → логарифм не нужен
- **Разная база и разброс** → z-стандартизация всех признаков
- **Выбросы** (|z| > 2,5: ЯНАО, ХМАО, Чукотка, Якутия, ЕАО, Марий Эл) не удаляем — это реальные регионы с особым профилем
- **Высокие значения** — Северо-Восток, нефтегазовые АО, Москва; низкие — Центр и Поволжье

Две оси: общий уровень и «ПК против смартфона»

Корреляции и метод главных компонент по z-оценкам: какие различия между регионами главные и нет ли дублирующих признаков





r = 0,96

интернет и ШПД почти дублируют друг друга; с ежедневным использованием r = 0,80–0,83, с ПК — 0,42–0,62

PC1 = 78,5 %

общий уровень цифровизации: все нагрузки положительны (0,40–0,55)

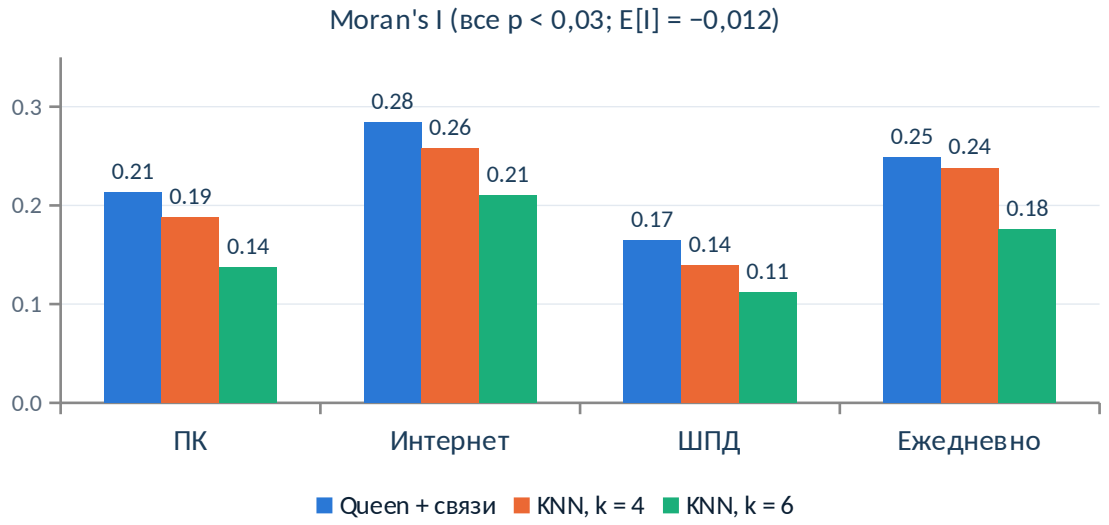
PC2 = 15,6 %

ПК (+0,88) против ежедневного онлайна (−0,44): «компьютерная» или «мобильная» модель

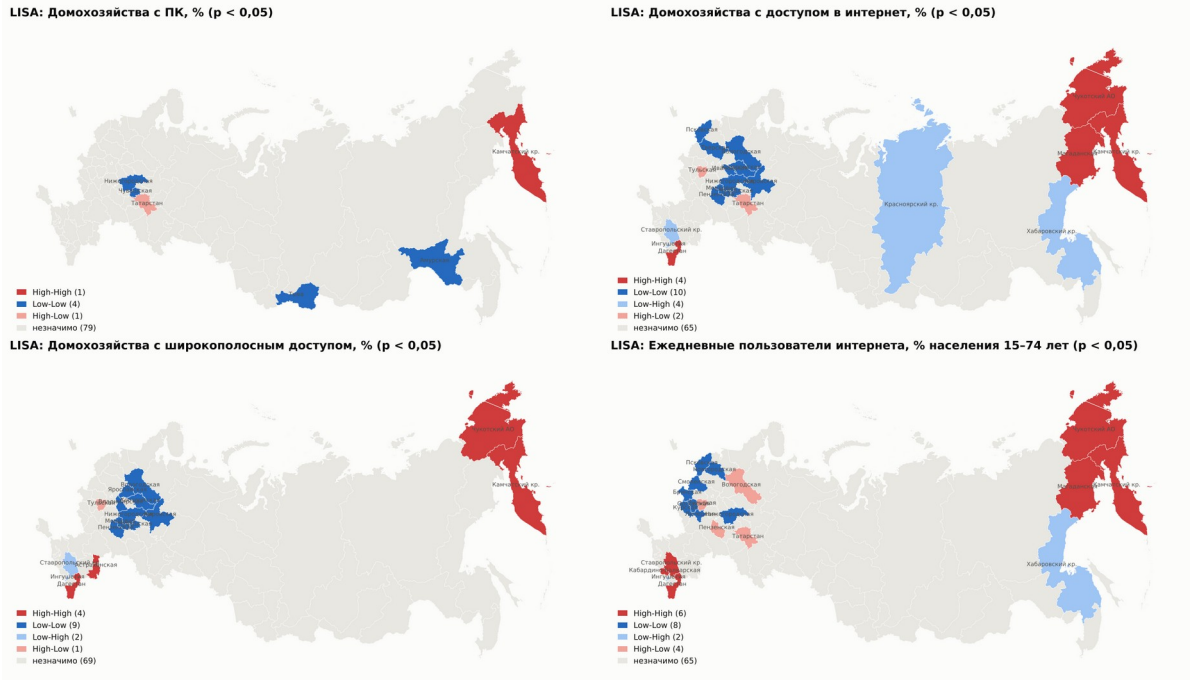
- **Основное пространство — 4 z-оценки:** прямая интерпретация, все показатели задания
- **Проверки:** 3 признака без ШПД (дубль) и 2 главные компоненты (94 % дисперсии) — раздел «Устойчивость»
- **Обе компоненты пространственно автокоррелированы:** I = 0,23 и 0,25, p ≤ 0,002

Соседи похожи значимо, но умеренно: сплошных зон мало

Moran's I и Geary's C (9 999 перестановок) при трех схемах соседства; локально — LISA и многомерный индекс Гири



LISA, p < 0,05	High-High	Low-Low	High-Low	Low-High	после FDR
ПК	1	4	1	0	0
Интернет	4	10	2	4	4
ШПД	4	9	1	2	3
Ежедневно	6	8	4	2	1



- **High-High:** Камчатка, Чукотка, Магадан; Дагестан, КБР, Ставрополье. **Low-Low:** Центр и Поволжье
- **Многомерный Гири:** 13 регионов похожи на соседей, 6 отличаются, 66 — незначимо
- **I падает при расширении соседства → связь действует на коротких расстояниях**

Семь методов: от типологии к жесткому районированию

Ноутбук 03: все методы работают с одними признаками (4 z-оценки) и одним графом соседства; k = 5 для всех, кроме Max-p

№	Метод	Учет соседства	Как работает	Параметры
1	**k-средних**	нет	минимизирует сумму квадратов расстояний до центров кластеров	k = 5, 200 стартов k-means++
2	Уорд	нет	иерархически объединяет кластеры с наименьшим ростом суммы квадратов	k = 5; для сверки с k-средних
3	**ClustGeo**	мягкий	Уорд на смеси различий: признаковых D_0 и географических D_1 (шаги по графу)	α = 0,25 — вес географии
4	Уорд со смежностью	жесткий	Уорд, но объединяются только соседние кластеры	connectivity = W
5	SKATER	жесткий	строит минимальное остовное дерево графа и режет его k − 1 раз	≥ 3 региона в кластере
6	AZP	жесткий	случайные связные зоны + перенос регионов между соседними зонами	случайный старт
7	Max-p	жесткий	максимум связных кластеров при пороге населения, затем локальный поиск	население ≥ 15 млн → p = 8



однородность по признакам — **территориальная связность**

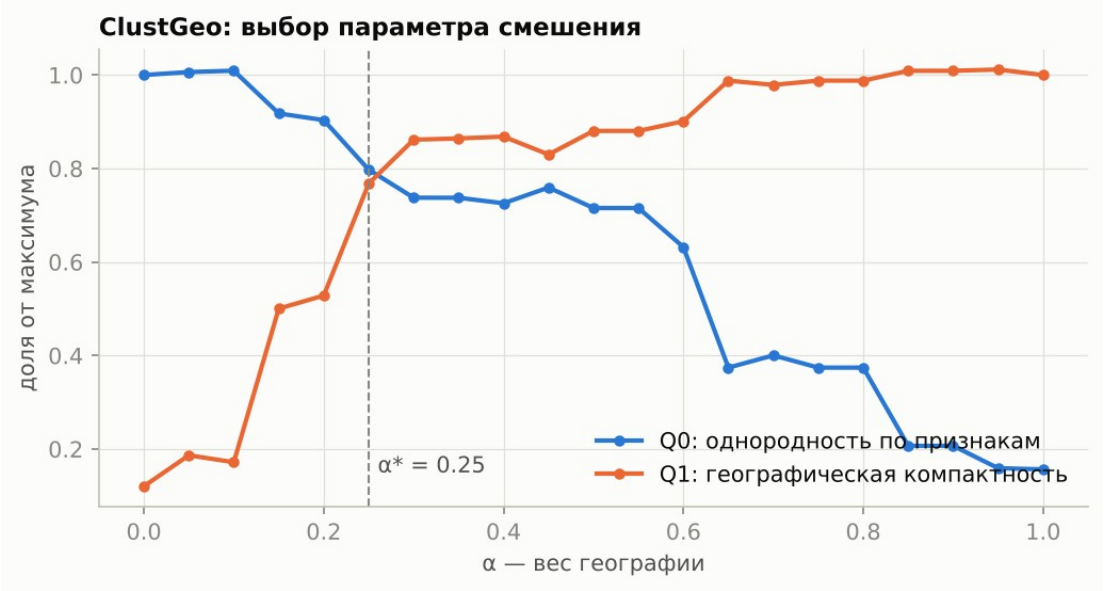
Ожидание из диагностики: чем жестче требование связности, тем выше доля соседей в одном кластере и тем ниже однородность по признакам. Вопрос сравнения — сколько однородности стоит связность.

k = 5: равноценен k = 4, но выделяет второй полюс PC2

Для k-средних при k = 3…7: силуэт, R^2, размер наименьшего кластера и устойчивость к шуму уровня ошибки выборки (100 повторов)

k	Силуэт	R^2	Мин. кластер	ARI, σ = 1 п. п.	ARI, σ = 2 п. п.
3	**0,399**	0,66	9	0,78	0,63
4	0,317	0,74	12	**0,85**	**0,67**
5	0,322	0,78	7	0,81	0,64
6	0,291	0,81	6	0,71	0,53
7	0,287	**0,83**	4	0,63	0,48

- **k = 3** — лучший силуэт, но «мобильный» тип сливается со средним: теряется PC2
- **k = 4 и 5** близки: силуэт 0,317/0,322; k = 4 чуть устойчивее, k = 5 объясняет больше (R^2 0,78)
- **k ≥ 6** — устойчивость падает до 0,71 и ниже, появляются кластеры из 4–6 регионов
- **Решили содержательно:** при k = 5 из 4 типов выделяются «Развитые» (много ПК) — второй полюс PC2; разбиения вложены, ARI(k4, k5) = 0,81



α ClustGeo — по критерию авторов метода

Q0 — доля объясненной неоднородности по признакам, Q1 — по географии, обе нормированы на максимум. При α = 0,25 кривые пересекаются (0,80 и 0,77): потеря однородности признаков уравновешена выигрышем географической.

Связность стоит больше половины однородности

R^2 падает с 0,78 у k-средних до 0,28–0,39 у жестких методов. Каждое разбиение оценено по четырем группам критериев; средний ранг — по группам с равными весами

Качество

$R^2 = 1 - SS_{внутр} / SS_{общ}$; силуэт (−1…1)

Устойчивость

ARI с исходным при шуме σ = 1 и 2 п. п. (100 повторов); ARI при наборе без ШПД

Пространство

фрагменты (мин. = k); доля пар соседей в одном кластере; путевой силуэт

Интерпретируемость

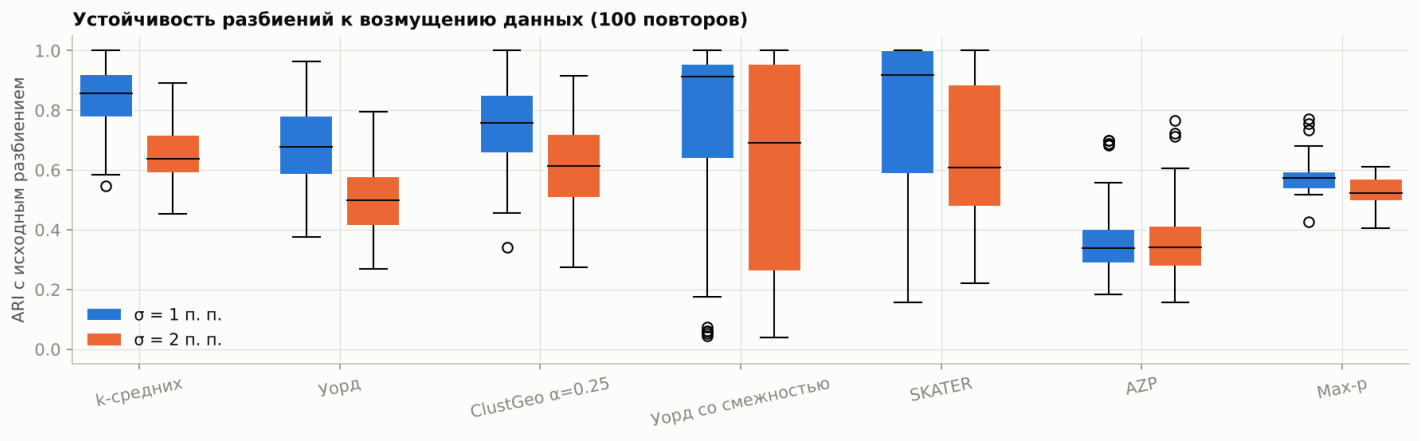
мин. размер кластера; мин. расстояние между центрами типов (σ)

Метод	R^2	Силуэт	ARI σ=1	ARI σ=2	ARI без ШПД	Фрагменты	Соседи в кластере	Путевой силуэт	Мин. размер	Разрыв центров	Средний ранг
k-средних	0,78	0,32	0,84	0,65	0,60	36	0,31	−0,10	7	1,48	3,00
Уорд	0,77	0,30	0,67	0,50	0,59	35	0,30	−0,11	6	1,43	4,42
ClustGeo α=0,25	0,62	0,02	0,75	0,62	0,88	16	0,60	0,15	9	0,58	3,38
Уорд со смежностью	0,38	0,11	0,72	0,62	0,73	5	0,88	0,08	2	0,64	3,65
SKATER	0,32	−0,05	0,82	0,68	0,69	5	0,84	0,27	3	0,64	3,48
AZP	0,28	−0,07	0,36	0,36	0,59	5	0,56	0,05	13	0,64	4,96
Max-p (p = 8)	0,38	−0,12	0,59	0,53	0,64	8	0,51	0,11	5	0,18	5,12

Зеленым — лучшее значение, оранжевым — худшее. Жесткие методы дают сплошные кластеры (5 фрагментов), но силуэт около нуля и вырожденные размеры (2–3 региона рядом с кластером из 62). Max-p при p = 8 сравним только по относительным метрикам.

k-средних устойчив к шуму; методы с соседством — нет

К процентам добавлен шум N(0, σ²), σ = 1 и 2 п. п. (≈ ошибка выборки при n ≈ 1000), признаки заново стандартизованы, метод перезапущен



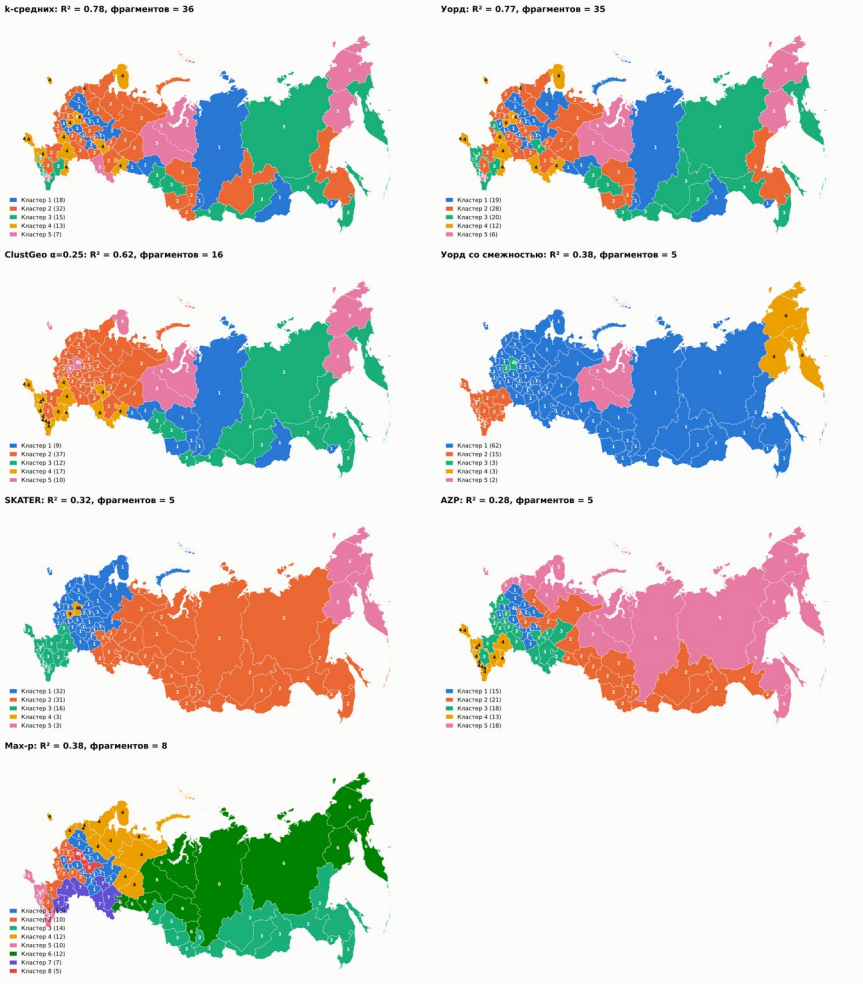
Метод	Без ШПД	2 ГК	W = KNN-6	Худший ARI, σ=1
k-средних	0,60	**0,98**	не зависит	**0,55**
Уорд	0,59	0,73	не зависит	0,38
ClustGeo	**0,88**	0,55	**0,42**	0,34
Уорд со смежн.	0,73	0,96	0,17	0,04
SKATER	0,69	0,42	0,26	0,16
AZP	0,59	0,72	0,16	0,18
Max-p	0,64	0,62	0,37	0,43

Что показали проверки

- **Шум:** k-средних 0,84 / 0,65 (σ = 1 / 2); Уорд заметно хуже (0,67), AZP хуже всех (0,36)
- **Схема соседства:** при замене Queen на KNN-6 жесткие методы почти полностью перестраиваются (ARI 0,16–0,37) — их результат во многом задан матрицей весов
- **Набор признаков:** без ШПД разбиение k-средних меняется (ARI 0,60); с 4 признаками оно устойчивее (0,84 против 0,71)
- **2 главные компоненты:** ARI 0,98 — слабая проверка: расстояния почти не меняются
- **Худшие случаи:** отдельные возмущения полностью перестраивают Уорда со смежностью (0,04)

Итог — k-средних; ClustGeo — территориальная версия

Карты всех семи разбиений и сводный рейтинг; проверено, меняется ли победитель при удвоенном весе каждой группы критериев



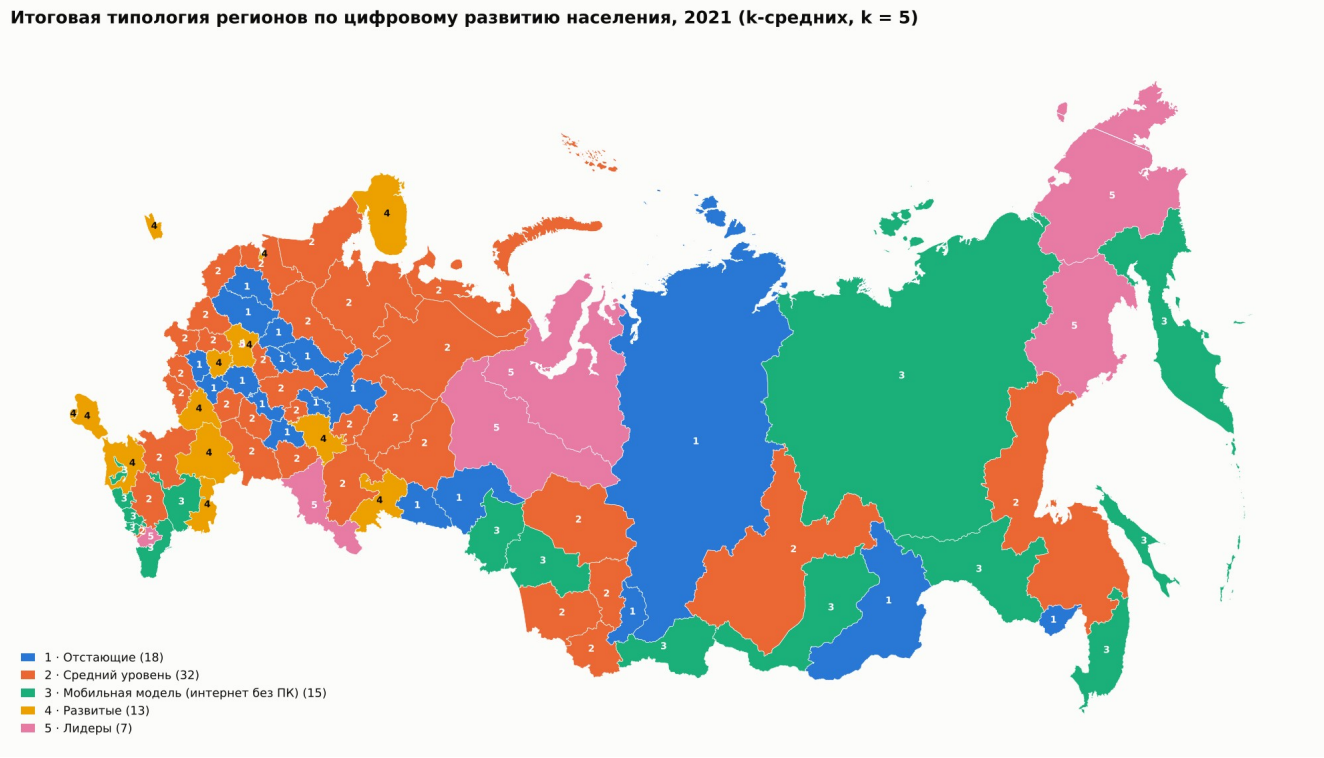
Метод	Равные веса	×2 качество	×2 устойч.	×2 простр.	×2 интерпр.
k-средних	**3,00**	**2,60**	**2,93**	3,67	**2,80**
ClustGeo	3,38	3,40	3,23	3,37	3,50
SKATER	3,48	3,88	3,18	**3,12**	3,73
Уорд со смежн.	3,65	3,72	3,52	3,38	3,97
Уорд	4,42	3,93	4,73	4,87	4,13
AZP	4,96	5,27	5,30	4,70	4,57
Max-p	5,13	5,20	5,10	4,90	5,30

Средний ранг (меньше — лучше)

- **k-средних первый в 4 из 5 вариантов весов;** только при удвоенном весе пространства первым становится SKATER
- **Цель задания — типология сходных регионов,** поэтому выбираем k-средних: максимум однородности и устойчивости
- **ClustGeo оставляем для карт:** вдвое больше соседей в кластере (0,60 против 0,31) при $R^2 = 0,62$

Пять типов регионов по цифровому развитию населения

k-средних, k = 5: R^2 = 0,78, силуэт 0,32, ARI при шуме 0,84; отрицательный силуэт только у 2 из 85 (Новосибирская, Оренбургская)



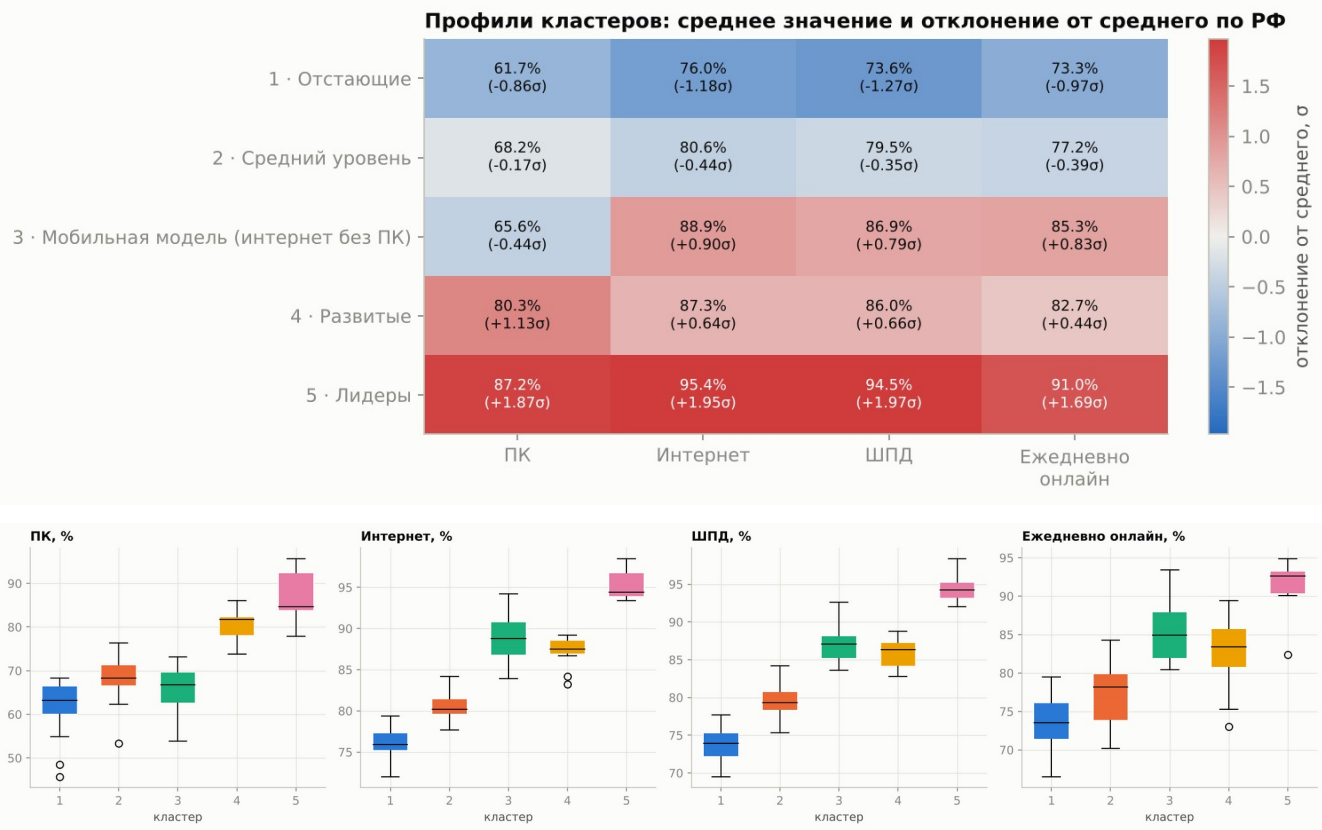
Тип	n	Нас., млн	ПК	Интернет	ШПД	Ежедн.
1 · Отстающие	18	18,4	61,7	76,0	73,6	73,3
2 · Средний уровень	32	54,9	68,2	80,6	79,5	77,2
3 · Мобильная модель	15	16,3	65,6	**88,9**	86,9	85,3
4 · Развитые	13	37,5	**80,3**	87,3	86,0	82,7
5 · Лидеры	7	18,5	87,2	95,4	94,5	91,0

Средние значения, % · жирным — особенность типа

- **Отстающие:** Тверская, Костромская, Ярославская, Кировская, Марий Эл, Мордовия, Хакасия, Забайкалье, ЕАО и др.
- **Мобильная модель:** интернет +0,9σ при ПК −0,4σ — Дагестан, КБР, Тыва, Бурятия, Якутия, Приморье, Камчатка
- **Развитые:** много ПК (+1,1σ) — Подмосковье, СПб, Краснодарский кр., Татарстан, Крым, Севастополь
- **Лидеры:** +1,7–2,0σ — Москва, ХМАО, ЯНАО, Чукотка, Магадан, Оренбург, Чечня

Типы различаются уровнем и структурой: ПК или смартфон

Профили — отклонение средних типа от среднего по РФ в σ; распределение типов по федеральным округам — из справочника регионов

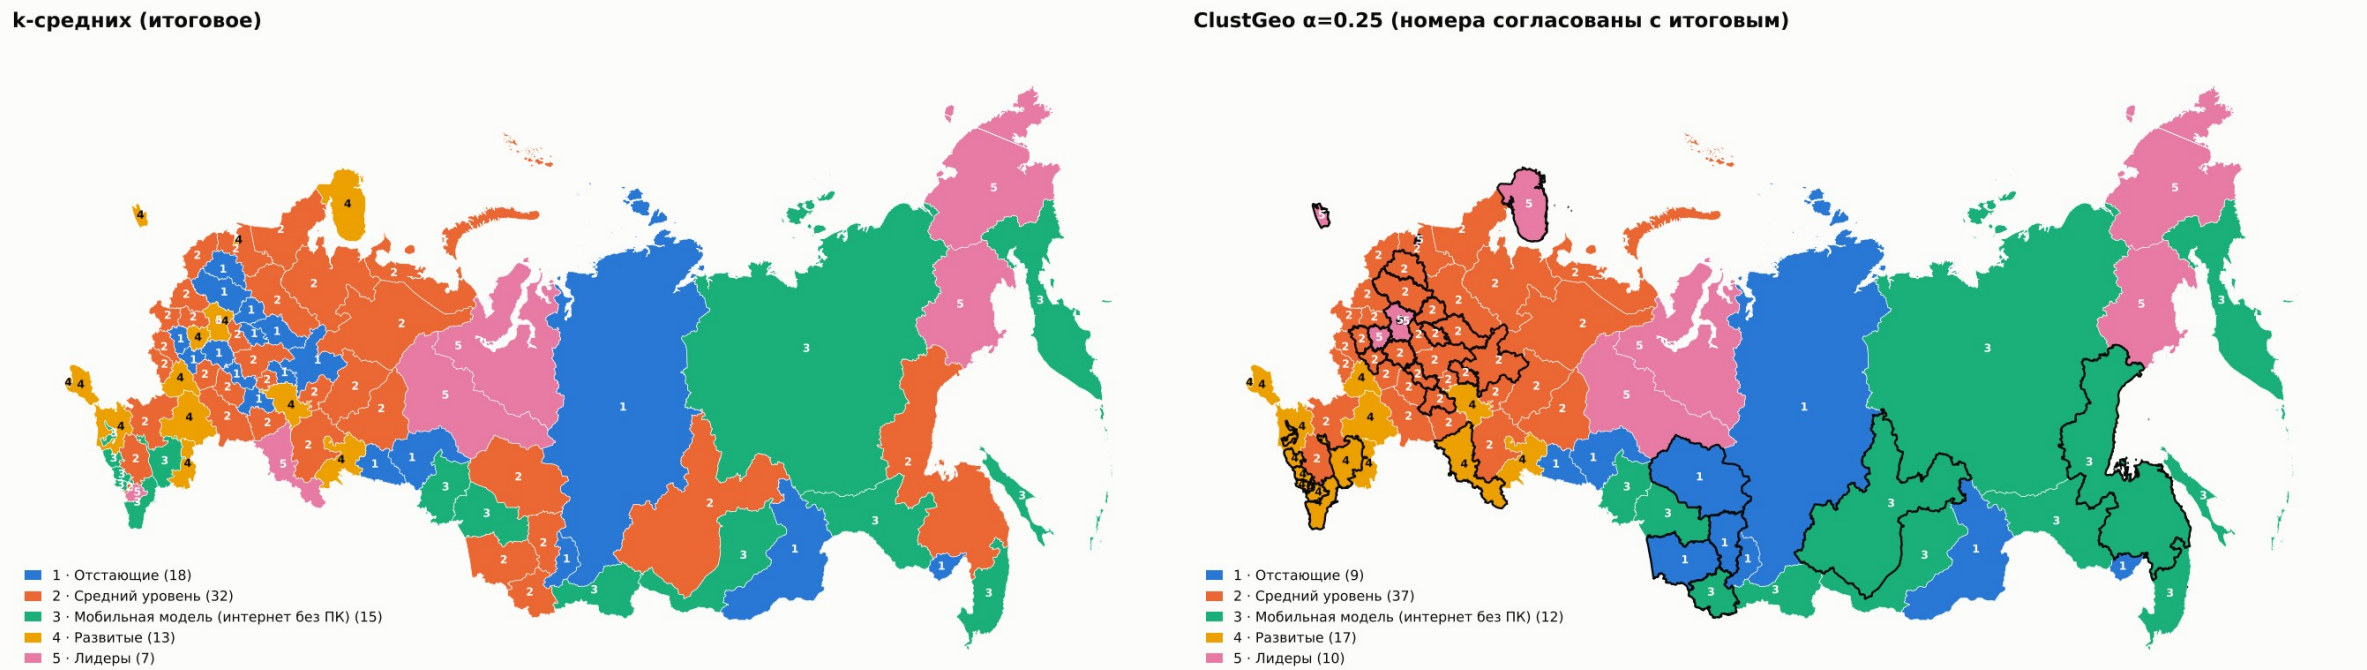


Округ	Отст.	Средн.	Моб.	Разв.	Лид.
Центральный	7	7	0	3	1
Северо-Западный	1	7	0	3	0
Южный	0	1	2	5	0
Северо-Кавказский	0	2	4	0	1
Приволжский	4	8	0	1	1
Уральский	2	1	0	1	2
Сибирский	2	5	3	0	0
Дальневосточный	2	1	6	0	2

- «Мобильная модель» — только Северный Кавказ, юг, Сибирь и Дальний Восток
- 11 из 18 «отстающих» — Центральный и Приволжский округа
- «Развитые» — регионы крупнейших агломераций и курортный юг
- Каждый округ содержит 3–5 типов: округ не определяет тип региона

Неравенство мозаичное: значимых сгущений типов нет

Join count (9 999 перестановок): больше ли пар соседей одного типа, чем при случайном размещении; справа — та же типология с учетом географии (ClustGeo)



Тип	Регионов	Пар соседей: набл.	ожид.	p
Отстающие	18	13	8,2	0,06
Средний уровень	32	33	26,7	0,10
Мобильная модель	15	6	5,6	0,49
Развитые	13	5	4,2	0,39
Лидеры	7	2	1,1	0,31

0 из 5

типов значимо сгущены (p < 0,05); ближе всех «Отстающие», p = 0,06

53 из 85

регионов сохраняют тип при учете географии (ClustGeo)

Сверка вариантов: ядра совпали, ошибки — в обоснованиях

Участники решали задачу независимо, затем варианты сравнили по одним критериям и собрали одно итоговое решение

0,65

ARI между итоговыми типологиями вариантов

15/15 · 7/7 · 16/18

совпали «мобильная модель», «лидеры», «отстающие»

10

ошибок найдено при сверке и исправлено

Вариант	Ошибка	Как исправлено
А: 3 признака, k = 4	Исключили ШПД как дубль: устойчивость 0,71 против 0,84, разбиение иное (ARI 0,60)	4 признака — основа, 3 — проверка
А	Мягкий учет соседства «лагом» — прием без опоры на литературу, зависит от W (ARI 0,37)	заменен на ClustGeo
А	Схема «соседи в пределах расстояния» без оговорки: до 52 соседей; не учли границы Москвы до 2012 г.; ошибка в составе LISA	схема отвергнута; добавлено в ограничения; исправлено до сдачи
Б: 4 признака, k = 5	Обоснование k: «силуэт максимален при k = 5», а при k = 3 он выше (0,40 > 0,32)	добавлена устойчивость по k, довод содержательный
Б	Совпадение с разбиением по 2 ГК (ARI 0,98) подано как доказательство устойчивости	оставлено с оговоркой + проверки без ШПД и с KNN-6
Б	30 повторов; не проверена зависимость от схемы соседства; рейтинг без проверки весов	100 повторов; KNN-6; рейтинг при удвоенных весах

Выводы и ограничения

Выводы

- **Две оси цифровизации:** общий уровень (78,5 %) и «ПК против смартфона» (15,6 %)
- **Соседство значимо, но умеренно:** I = 0,17–0,28 при любой схеме соседства
- **Пять типов (k-средних):** R^2 0,78, ARI 0,84; ядра совпали в двух независимых вариантах
- **Жесткое районирование теряет > 50 % однородности** и зависит от схемы соседства
- **Неравенство мозаичное →** адресная политика для регионов, а не программы по федеральным округам

Ограничения

- Выборочное обследование и самооценки; ошибка выборки не публикуется
- Один год (2021): ни динамики, ни причинности
- Результат чувствителен к набору признаков, k и схеме соседства
- MAUP: субъекты несопоставимы по площади, город и село не различаются
- Связи Калининград, Сахалин, Крым — допущение для связности графа